Análisis multivariante del sector hotelero

PROYECTO 6: HOTELES

Andrea Millán, Diego Gullón y Julia Guerrero

CEU

Curso 2025–2026

Introducción..... 3
Estudio descriptivo de la Base de datos..... 4
MODELO DE REGRESIÓN LINEAL MÚLTIPLE..... 8
ANÁLISIS FACTORIAL..... 12
ANÁLISIS DISCRIMINANTE LINEAL (LDA)..... 16
MODELO LOGÍSTICO MULTINOMIAL..... 21

Introducción

Actualmente, el sector hotelero se encuentra en un entorno muy competitivo, donde conocer mejor el comportamiento de los clientes resulta fundamental para poder adaptar la oferta y mejorar la gestión del negocio. A la hora de reservar unas vacaciones, los viajeros suelen tener en cuenta diferentes factores como el precio, el tipo de habitación, la categoría del hotel, la antelación con la que realizan la reserva o los servicios incluidos en la estancia. Por ello, analizar de forma conjunta todas estas variables permite entender mejor qué elementos influyen en la decisión de reserva y en el precio final que paga el cliente.

En este trabajo se utilizarán distintas técnicas de estadística multivariante aplicadas a una base de datos del sector hotelero, con el objetivo de extraer información útil para interpretar patrones de comportamiento y apoyar la toma de decisiones. En primer lugar, se desarrollará un modelo de regresión múltiple para estudiar qué variables explican mejor el precio de las habitaciones. Después, se aplicará un análisis discriminante para clasificar reservas o perfiles de clientes a partir de una variable objetivo seleccionada. Por último, se estimará un modelo de elección discreta para analizar qué factores influyen en el régimen de estancia contratado por los huéspedes. A través de estos tres enfoques se busca no solo obtener modelos con buena capacidad predictiva, sino también interpretar los resultados desde una perspectiva práctica dentro de la gestión hotelera.

Estudio descriptivo de la Base de datos

1. **Contraste de aleatoriedad**

H0: cada una de las variables es un muestreo aleatorio simple
Hi: cada una de las variables no se comporta como un muestreo aleatorio simple

Resumen de contrastes de hipótesis

	Hipótesis nula	Prueba	Sig.[a]	Decisión
1	La secuencia de valores definida por room_price<=163,22 y >163, 22 es aleatoria.	Prueba de rachas para una muestra	,694	Conserve la hipótesis nula.
2	La secuencia de valores definida por hotel_code = y es aleatoria.	Prueba de rachas para una muestra	.[b]	No se puede calcular.
3	La secuencia de valores definida por day_of_week = y es aleatoria.	Prueba de rachas para una muestra	.[b]	No se puede calcular.
4	La secuencia de valores definida por days_in_advance<=20 y >20 es aleatoria.	Prueba de rachas para una muestra	,916	Conserve la hipótesis nula.
5	La secuencia de valores definida por months_in_advance = y es aleatoria.	Prueba de rachas para una muestra	.[b]	No se puede calcular.
6	La secuencia de valores definida por room_type = y es aleatoria.	Prueba de rachas para una muestra	.[b]	No se puede calcular.
7	La secuencia de valores definida por hotel_category = y es aleatoria.	Prueba de rachas para una muestra	.[b]	No se puede calcular.
8	La secuencia de valores definida por rooms_booked = y es aleatoria.	Prueba de rachas para una muestra	.[b]	No se puede calcular.
9	La secuencia de valores definida por guests_per_room = y es aleatoria.	Prueba de rachas para una muestra	.[b]	No se puede calcular.
10	La secuencia de valores definida por meal_plan = y es aleatoria.	Prueba de rachas para una muestra	.[b]	No se puede calcular.
11	La secuencia de valores definida por cancellation_policy = y es aleatoria.	Prueba de rachas para una muestra	.[b]	No se puede calcular.
12	La secuencia de valores definida por rooms_available<=16 y >16 es aleatoria.	Prueba de rachas para una muestra	<,001	Rechace la hipótesis nula.
13	La distribución de room_price es normal con la media 175,21 y la desviación estándar 74,24217.	Prueba de Kolmogorov-Smirnov para una muestra	<,001[c]	Rechace la hipótesis nula.
14	La distribución de days_in_advance es normal con la media 48 y la desviación estándar 66,497.	Prueba de Kolmogorov-Smirnov para una muestra	<,001[c]	Rechace la hipótesis nula.
15	La distribución de rooms_available es normal con la media 17 y la desviación estándar 9,640.	Prueba de Kolmogorov-Smirnov para una muestra	<,001[c]	Rechace la hipótesis nula.

a. El nivel de significación es de ,050.

b. El campo de prueba o el campo de prueba derivado no tiene exactamente dos valores.

c. El método de Lilliefors basado en las muestras 10000 Monte Carlo con la semilla de inicio 299883524.

Las variables de room price y days in advance su p-valor es mayor que el 5%, **aceptamos H0, por lo tanto provienen de un muestreo aleatorio simple y concluimos que el estudio se puede inferir en la población.**

Sin embargo, las demás variables son nominales o tienen un valor menor a 0,05, por lo tanto rechazamos H0 por lo que concluimos que el estudio no puede inferir en la población, únicamente en la muestra.

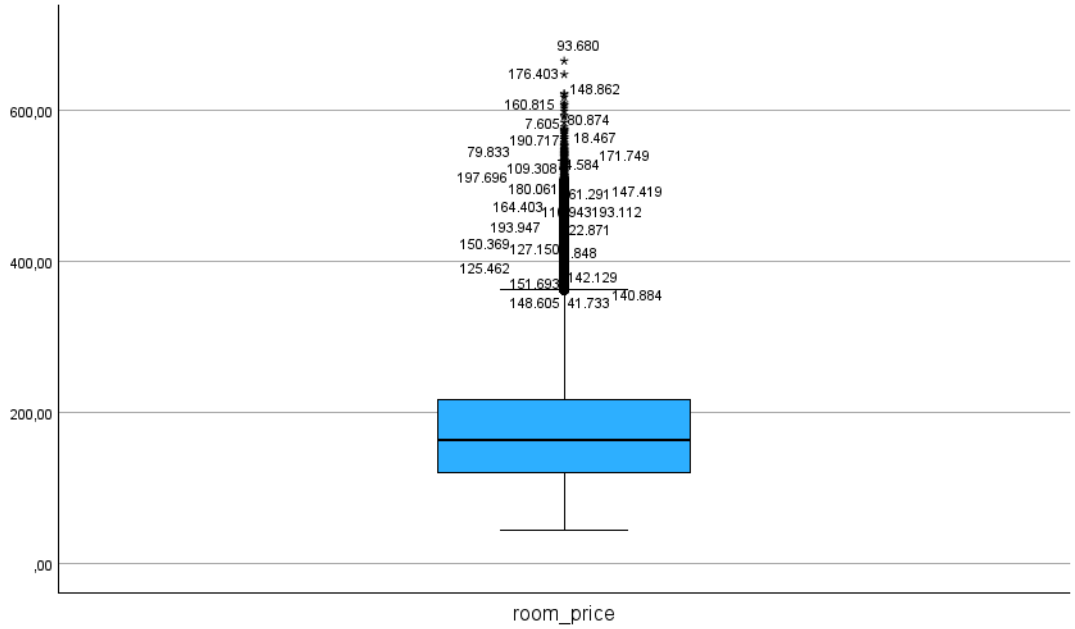
2. Análisis descriptivo y gráficos

Estadísticos descriptivos

	N	Mínimo	Máximo	Media	Desv. estándar	Varianza	Asimetría		Curtosis	
	Estadístico	Estadístico	Estadístico	Estadístico	Estadístico	Estadístico	Estadístico	Error estándar	Estadístico	Error estándar
room_price	200000	45,00	666,01	175,2129	74,24217	5511,901	,890	,005	,946	,011
days_in_advance	200000	0	360	47,77	66,497	4421,854	2,381	,005	5,912	,011
months_in_advance	200000	0	11	1,19	2,156	4,649	2,504	,005	6,421	,011
hotel_category	200000	3	5	4,05	,739	,546	-,079	,005	-1,167	,011
rooms_booked	200000	1	5	1,44	,792	,627	2,075	,005	4,476	,011
guests_per_room	200000	1	4	2,25	,829	,688	,558	,005	-,105	,011
rooms_available	200000	1	50	17,01	9,640	92,923	,475	,005	-,332	,011
N válido (por lista)	200000									

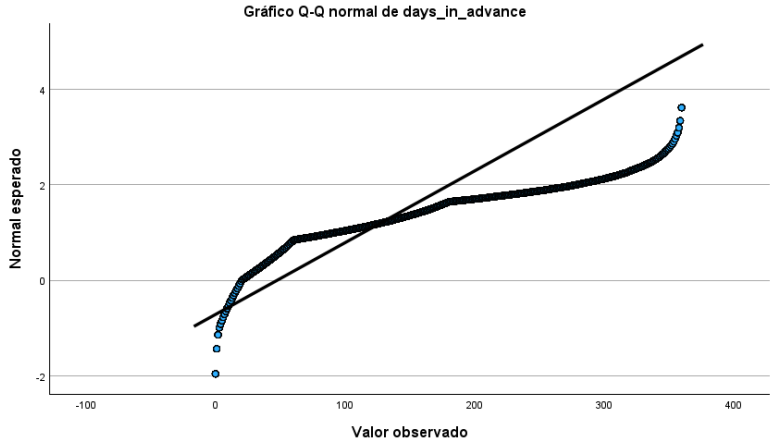
room price

- **diagrama de cajas y bigotes**



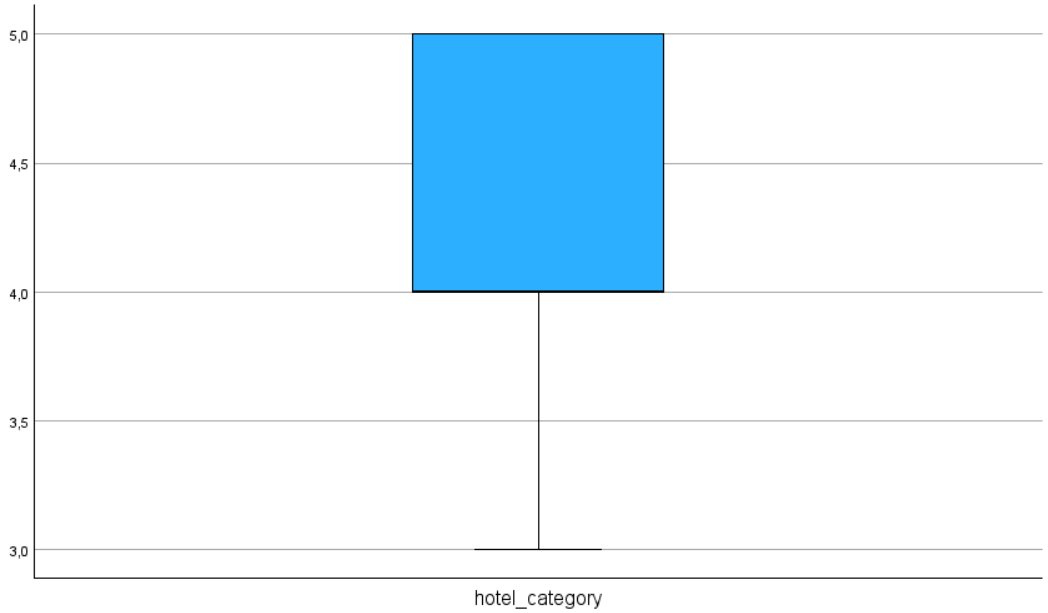
El diagrama de cajas de room_price muestra que la mayoría de los precios de las habitaciones se concentra en valores intermedios, con una mediana cercana a 160€. Además, podemos observar muchos valores atípicos en la parte superior, lo que refleja la existencia de algunas reservas con precios muy elevados y una distribución con asimetría positiva.

- **days in advance**



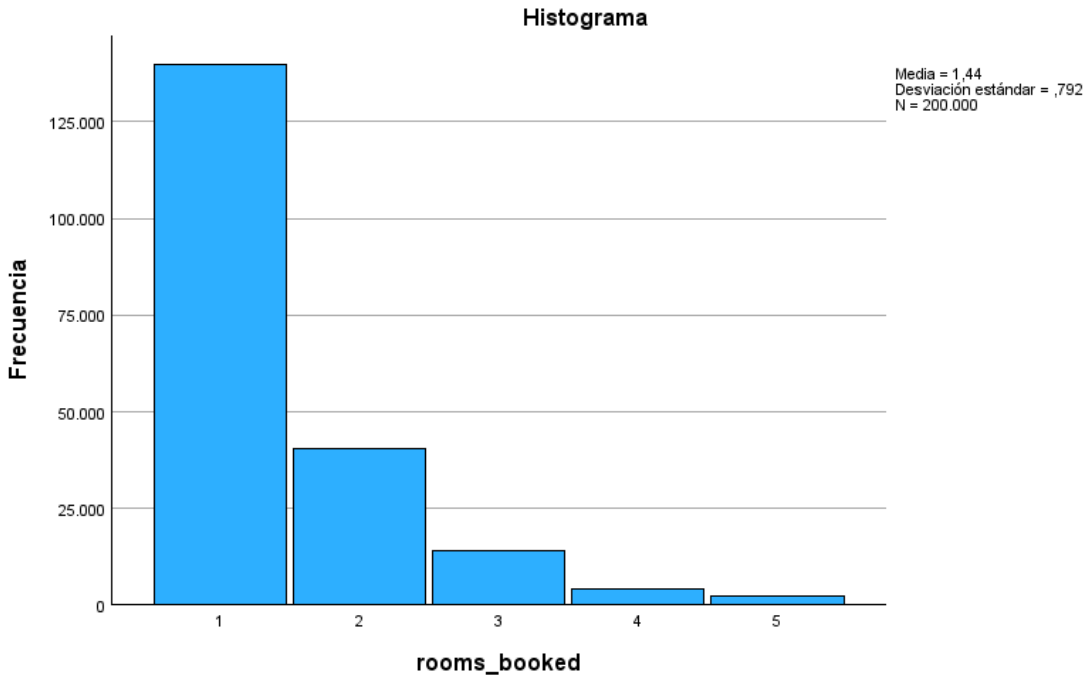
El gráfico Q-Q de days in advance muestra que los datos no siguen una distribución normal, ya que los puntos se alejan claramente de la línea de referencia, especialmente en los extremos. Esta curvatura indica asimetría en la distribución y sugiere la presencia de valores extremos, con reservas realizadas tanto con muy poca como con mucha antelación.

- **hotel category**



El diagrama de cajas de hotel_category muestra que la mayoría de las reservas se concentra en hoteles de categoría media-alta y alta, con valores principalmente entre 4 y 5 estrellas y una mediana situada en ese rango. Además, el mínimo se sitúa en torno a 3 estrellas y no se aprecian valores atípicos, lo que indica que apenas hay reservas en categorías extremas (1 y 2 estrellas) y que la distribución de la variable es bastante compacta dentro del intervalo 3-5 estrellas.

- **rooms_booked**



El histograma de rooms_booked confirma que la gran mayoría de las reservas corresponden a 1 habitación, con una frecuencia de unos 125.000 casos, seguida de 2 habitaciones (alrededor de 45.000). La distribución es altamente asimétrica positiva, con frecuencias decrecientes para 3 (25.000), 4 (unos 10.000) y 5 habitaciones (muy bajas), y una media de 1,44 que refleja el sesgo hacia reservas individuales o de parejas.

2.1. Tema 1. Regresión Múltiple

MODELO DE REGRESIÓN LINEAL MÚLTIPLE

El presente estudio tiene como objetivo identificar y cuantificar el impacto de diversas variables operativas y de mercado sobre el precio de las habitaciones de hotel. Para ello, se ha ajustado un modelo de regresión lineal múltiple donde la **variable dependiente** (objetivo) es el **precio de la habitación (room_price)**.

Añadimos al modelo la variable Efecto finde como una **variable Dummy**, donde recodificamos la variable "days_of_the_week" donde en esta nueva variable nos da el valor 0 para los siguientes días: lunes, martes, miércoles y jueves (entre semana) ; y 1 para: viernes, sábado y domingo (fin de semana)

Como variables independientes (explicativas) se han incluido:

- Temporales/Reserva: Días de antelación (days_in_advance) y meses de antelación (months_in_advance).
- Características del alojamiento: Categoría del hotel (hotel_category) y número de huéspedes por habitación (guests_per_room).
- Oferta y Demanda: Habitaciones reservadas en la operación (rooms_booked) y habitaciones disponibles en el hotel (rooms_available).
- Efecto Calendario: Se ha incluido una variable cualitativa dicotómica o dummy (Efecto finde), donde 1 representa reservas en fin de semana y 0 entre semana.

Coeficientes[a]

Modelo		Coeficientes no estandarizados		Coeficientes estandarizados			95,0% intervalo de confianza para B		Estadísticas de colinealidad	
		B	Desv. Error	Beta	t	Sig.	Límite inferior	Límite superior	Tolerancia	VIF
1	(Constante)	-92,847	,786		-118,068	<,001	-94,388	-91,306		
	days_in_advance	-,870	,013	-,779	-68,333	<,001	-,895	-,845	,017	60,116
	months_in_advance	23,114	,393	,671	58,846	<,001	22,344	23,884	,017	60,116
	hotel_category	70,436	,149	,701	472,830	<,001	70,144	70,728	,984	1,016
	rooms_booked	-1,074	,138	-,011	-7,782	<,001	-1,344	-,803	1,000	1,000
	guests_per_room	4,951	,132	,055	37,597	<,001	4,693	5,210	1,000	1,000
	rooms_available	-,997	,012	-,129	-83,889	<,001	-1,021	-,974	,908	1,101
	Efecto finde	12,840	,242	,081	53,069	<,001	12,366	13,314	,922	1,084

a. Variable dependiente: room_price

H0: b=0
H1: b=/0

Al analizar la tabla de coeficientes, se observa que el estadístico t arroja un p-valor (Sig.) inferior a 0,001 para la totalidad de las variables independientes. Al ser este valor estrictamente menor que el nivel de significación habitual 0,05, **se rechaza la hipótesis nula** en todos los casos. Esto indica que **todas las variables** propuestas aportan **información estadísticamente significativa** para la predicción del precio de la habitación.

El valor de la constante sale **-92,847.** No tiene sentido que la estimación del precio parta de un valor negativo, por lo que en este caso el valor de la constante lo **eliminamos para el modelo.**

Una vez evaluada la significatividad global del modelo y la capacidad explicativa de las variables independientes, es un requisito metodológico indispensable proceder a la **fase de validación.**

- **Multicolinealidad**

Estadísticas de colinealidad	
Tolerancia	VIF
,017	60,116
,017	60,116
,984	1,016
1,000	1,000
1,000	1,000
,908	1,101
,922	1,084

El primer supuesto a evaluar para garantizar la fiabilidad estructural del modelo es la ausencia de multicolinealidad. Esto implica **verificar que las variables explicativas no estén altamente correlacionadas entre sí**, evitando así la redundancia de información que podría inflar la varianza de los estimadores y distorsionar la significatividad del modelo.

Para llevar a cabo este diagnóstico, se han analizado las Estadísticas de colinealidad, específicamente la **Tolerancia** y el Factor de Inflación de la Varianza **(VIF).** Metodológicamente, se considera que existe un problema grave de colinealidad cuando los niveles de tolerancia son **inferiores a 0,10** y/o los valores **VIF superan el umbral crítico de 10.**

Al examinar los resultados obtenidos en la tabla, se observa que la **gran mayoría de las variables presentan un comportamiento óptimo**, con estadísticos VIF muy cercanos a 1 (fluctuando entre 1,000 y 1,101) y niveles de tolerancia robustos (superiores a 0,900).

Sin embargo, se detecta una infracción crítica del supuesto en las **dos primeras variables (Días de antelación (days_in_advance) y meses de antelación (months_in_advance))** del modelo. Ambas variables arrojan niveles de Tolerancia idénticos y deficientes de **0,017**, acompañados de un **VIF extremo de 60,116**. Estos valores, que superan ampliamente el límite permitido, confirman la existencia de una multicolinealidad estructural severa. Como se anticipó en el análisis de coeficientes, estas variables representan la misma dimensión temporal (días y meses de antelación de la reserva).

Debido a esta multicolinealidad, la solución es eliminar una de las dos variables. En este caso, vamos a **eliminar la variable days_in_advance**, ya que ambas explican lo mismo.

A continuación se encuentra la tabla de coeficientes, con la modificación realizada.

Coeficientes[a]

Modelo		Coeficientes no estandarizados		Coeficientes estandarizados			95,0% intervalo de confianza para B		Estadísticas de colinealidad	
		B	Desv. Error	Beta	t	Sig.	Límite inferior	Límite superior	Tolerancia	VIF
1	(Constante)	-102,790	,782		-131,483	<,001	-104,322	-101,257		
	months_in_advance	-3,502	,051	-,102	-68,335	<,001	-3,602	-3,402	1,000	1,000
	hotel_category	70,434	,151	,701	467,396	<,001	70,139	70,730	,984	1,016
	rooms_booked	-1,050	,140	-,011	-7,523	<,001	-1,324	-,776	1,000	1,000
	guests_per_room	4,982	,133	,056	37,399	<,001	4,721	5,244	1,000	1,000
	rooms_available	-,998	,012	-,130	-82,967	<,001	-1,021	-,974	,908	1,101
	Efecto finde	12,801	,245	,081	52,302	<,001	12,322	13,281	,922	1,084

a. Variable dependiente: room_price

- **Incorrelacion (Durbin Watson)**

Resumen del modelo[b]

Modelo	R	R cuadrado	R cuadrado ajustado	Error estándar de la estimación	Estadísticos de cambio					Durbin-Watson
					Cambio en R cuadrado	Cambio en F	gl1	gl2	Sig. Cambio en F	
1	,753[a]	,567	,567	48,84896	,567	37426,163	7	199992	<,001	1,990

a. Predictores: (Constante), Efecto finde, guests_per_room, months_in_advance, hotel_category, rooms_booked, rooms_available, days_in_advance

b. Variable dependiente: room_price

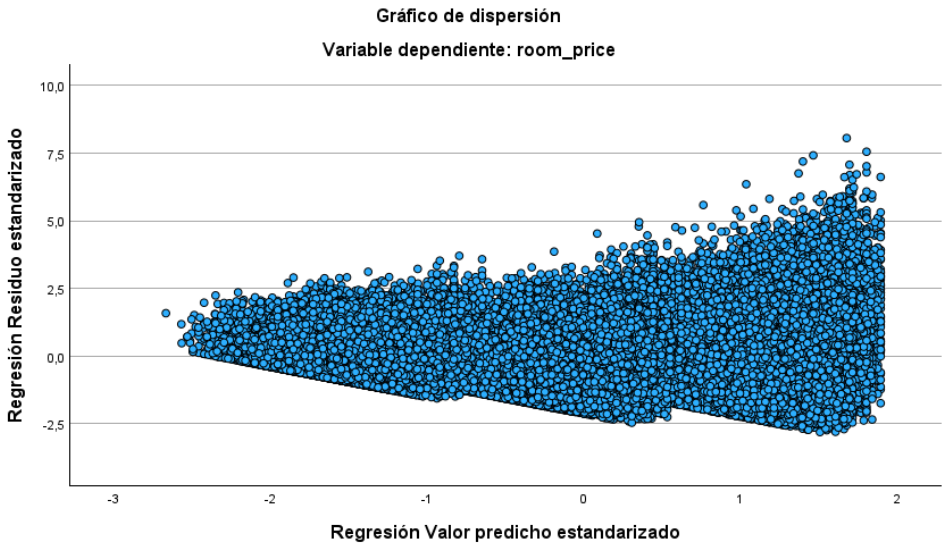
El segundo supuesto fundamental para la validez del modelo de regresión establece que **los residuos (errores) deben ser independientes entre sí;** es decir, no debe existir autocorrelación. El cumplimiento de este supuesto garantiza que el modelo no esté sesgado por patrones ocultos (efecto contagio entre observaciones) y que los contrastes de significatividad calculados previamente sean completamente fiables.

El valor de Durbin- Watson debe estar **entre 1,5 y 2,5** para que el modelo sea válido. En este caso el valor de Durbin-Watson es de **1,990,** por lo que los errores son independientes entre sí y el modelo es válido.

- **R^2 cuadrado y R^2 cuadrado ajustado**

El modelo presenta un coeficiente de determinación **R^2= 0,567**, lo que indica que el 56,7% de la varianza de la variable respuesta es explicada por el conjunto de predictores. El hecho de que e**l R^2 ajustado coincida exactamente (0,567)** sugiere que el modelo es altamente eficiente, ya que no incluye variables que penalicen el ajuste, y que el tamaño muestral es lo suficientemente robusto para validar la estabilidad de los resultados.

- **Estudio de residuos (Homocedasticidad)**



En conclusión, aunque el modelo es equilibrado y no comete errores sistemáticos (la media de sus errores es cero), el gráfico muestra un claro patrón en forma de embudo (**heterocedasticidad**). Esto significa que el modelo es muy preciso prediciendo habitaciones baratas, pero pierde el control y comete errores mucho más grandes al intentar predecir habitaciones caras. Cabe destacar que este efecto es muy típico y esperado en el sector hotelero: las habitaciones económicas tienen precios muy rígidos y fáciles de predecir, mientras que las habitaciones de lujo o suites sufren fluctuaciones de precio gigantescas dependiendo de la demanda, lo que dispara el margen de error del modelo en los valores más altos.

ANÁLISIS ANOVA

ANOVA[a]

Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	625149566,98	7	89307080,998	37426,163	<,001[b]
	Residuo	477225023,55	199992	2386,221		
	Total	1102374590,5	199999			

a. Variable dependiente: room_price

b. Predictores: (Constante), Efecto finde, guests_per_room, months_in_advance, hotel_category, rooms_booked, rooms_available, days_in_advance

H0: El modelo no tiene capacidad predictiva (ninguna variable influye).
HI: El modelo sí tiene capacidad predictiva (al menos una variable influye).

Tamaño de la muestra : 200.000 reservas (calculado a partir de los grados de libertad totales: 199.999 + 1). Representa una base de datos muy grande.

Estadístico F: 37.426,16. Un valor sumamente alto que indica que la capacidad explicativa del modelo supera por mucho al error aleatorio.

Significatividad (p-valor): < 0,001.

Dado que el p-valor (< 0,001) es estrictamente menor al nivel de tolerancia habitual (0,05), **se rechaza la hipótesis nula.** Por lo tanto el modelo de regresión múltiple es estadísticamente significativo a nivel global y es válido para estimar los precios de las habitaciones.

2.2. Tema 3. Análisis discriminante

ANÁLISIS FACTORIAL

El objetivo de aplicar esta técnica multivariante es reducir la dimensionalidad de nuestro conjunto de datos, agrupando las variables originales que están altamente correlacionadas en un número menor de variables latentes (factores o componentes). Esto nos permitirá explicar el comportamiento de las reservas hoteleras de forma más sencilla y con la menor pérdida de información posible.

Antes de extraer los factores, es fundamental comprobar si las variables están lo suficientemente correlacionadas entre sí. Para ello, utilizamos dos contrastes estadísticos:

Prueba de KMO y Bartlett

Medida Kaiser-Meyer-Olkin de adecuación de muestreo		,497
Prueba de esfericidad de Bartlett	Aprox. Chi-cuadrado	1005902,743
	gl	28
	Sig.	<,001

$$\begin{cases} H_0: \text{Las variables no están relacionadas} \\ H_1: \text{Las variables están relacionadas} \end{cases}$$

- **Medida de adecuación muestral de Kaiser-Meyer-Olkin (KMO):**

Hemos obtenido un valor de 0.497. Según los criterios estadísticos habituales de Kaiser, el umbral mínimo para considerar que un análisis factorial es aceptable es de 0.5. Al obtener un valor por debajo de este límite, la adecuación muestral se clasifica como "inaceptable". Esto significa que la proporción de varianza común entre las variables es demasiado baja y, estadísticamente, los datos no son idóneos para ser reducidos a factores subyacentes. Aunque el valor es muy próximo a 0,5

- **Prueba de esfericidad de Bartlett:**

Evalúa la hipótesis nula H0 de que la matriz de correlaciones es una matriz identidad (es decir, que las variables no están correlacionadas). Dado que el p-valor (Sig.) es < 0.01, menor a 0,05 rechazamos H0. Confirmamos que existe una correlación significativa entre las variables, justificando plenamente la aplicación del modelo.

Extracción de Factores y Varianza Total Explicada
Para determinar el número óptimo de componentes a retener, nos basamos en el Criterio de Kaiser, el cual dicta que se deben extraer aquellos componentes cuyos valores iniciales sean superiores a 1.

El modelo identifica 4 componentes principales con valores superiores a la unidad (Componente 1: 2,048; Comp. 2: 1,789; Comp. 3: 1,188; Comp. 4: 1,005).

El primer componente explica por sí sola el 25,595% de la variabilidad total. En conjunto, las cuatro componentes seleccionadas explican el 75,371% de la información total del modelo.

Este porcentaje de varianza se considera equilibrado, cumpliendo con el objetivo de reducir la dimensión sin perder una cantidad excesiva de información relevante del conjunto de datos de los hoteles.

Varianza total explicada

	Autovalores iniciales			Sumas de cargas al cuadrado de la extracción			Sumas de cargas al cuadrado de la rotación		
Componente	Total	% de varianza	% acumulado	Total	% de varianza	% acumulado	Total	% de varianza	% acumulado
1	2,048	25,595	25,595	2,048	25,595	25,595	1,999	24,983	24,983
2	1,789	22,368	47,963	1,789	22,368	47,963	1,731	21,638	46,621
3	1,188	14,850	62,813	1,188	14,850	62,813	1,294	16,170	62,791
4	1,005	12,558	75,371	1,005	12,558	75,371	1,006	12,580	75,371
5	,995	12,441	87,812						
6	,707	8,837	96,650						
7	,260	3,248	99,898						
8	,008	,102	100,000						

Método de extracción: análisis de componentes principales.

Interpretación de los factores extraídos

Matriz de componente[a]

	Componente			
	1	2	3	4
months_in_advance	,910	,408	,031	,001
hotel_category	-,346	,768	,393	,072
rooms_booked	,004	-,012	-,013	,713
guests_per_room	-,025	,057	,058	-,701
rooms_available	,173	-,448	,619	,009
Efecto finde	-,099	,276	-,775	-,020
room_price	-,476	,768	,211	,001
days_in_advance	,913	,403	,029	,001

Método de extracción: análisis de componentes principales.

a. 4 componentes extraídos.

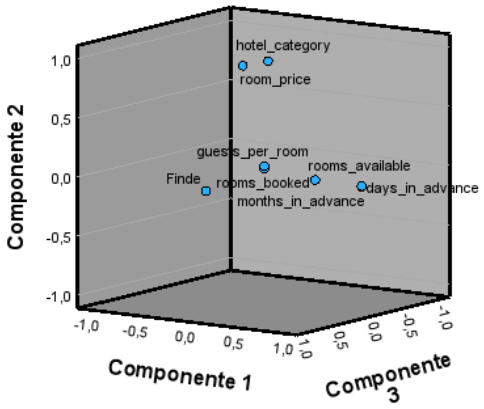
- **Componente 1: Anticipación de la reserva.** Presenta cargas muy elevadas en days_in_advance (0,913) y months_in_advance (0,910). Este factor resume la antelación con la que los clientes realizan sus reservas.

- **Componente 2: Segmento y Nivel de Precios.** Está fuertemente vinculado a hotel_category (0,768) y room_price (0,768). Estas variables definen el posicionamiento de mercado del hotel.

- **Componente 3: Disponibilidad y Temporalidad.** Se relaciona positivamente con rooms_available (0,619) y negativamente con Efecto finde (-0,775), sugiriendo que explica la variabilidad de la oferta según el momento de la semana.

- **Componente 4: Densidad de Ocupación.** Agrupa a rooms_booked (0,713) y guests_per_room (-0,701), reflejando el volumen de ocupación física del establecimiento.

Gráfico de componente en espacio rotado



En el gráfico vemos que para nuestro modelo las variables hotel category y room price son las más fuertes.

A partir de esta matriz de coeficientes de puntuación de componente podemos obtener una ecuación que nos permite resumir el comportamiento de cada individuo en pocas dimensiones a partir de una puntuación factorial. Esto lo podemos utilizar para segmentar o clasificar.

Matriz de coeficiente de puntuación de componente

	Componente			
	1	2	3	4
months_in_advance	,500	,016	,002	,002
hotel_category	,046	,558	-,115	-,038
rooms_booked	,001	,029	-,009	-,709
guests_per_room	,002	,011	-,014	,700
rooms_available	-,008	-,027	-,584	,003
Efecto finde	-,006	-,120	,661	-,003
room_price	-,018	,517	,035	,027
days_in_advance	,500	,012	,003	,001

Método de extracción: análisis de componentes principales.
Método de rotación: Varimax con normalización Kaiser.

Ejemplo componente 1

Y= 0,500*months_in_advance + 0,46 * hotel_category + 0,01 *rooms_booked + 0,002 *guest_per_room - 0,008*rooms_available - 0,18 *efecto finde + 0,50 * days_in_advance

La imagen muestra la base de datos resultante con las nuevas variables (FAC1_1, FAC2_1, FAC3_1, FAC4_1). Estas puntuaciones indican la posición relativa de cada observación en los factores:

Puntuaciones

- Positivas Altas: Indican que el hotel o cliente destaca por encima de la media en esa dimensión (por ejemplo, tiene mucha antelación o precios muy altos).
- Puntuaciones Negativas: Indican que la observación se sitúa por debajo del promedio en dicha dimensión.

FAC1_1	FAC2_1	FAC3_1	FAC4_1
-,05736	-,56721	,51473	,16737
-,48815	-,27042	-,14861	-,67358
,09666	1,32886	,01136	-1,63440
-,52374	1,11738	-,85654	1,84087
-,60117	-,14132	,38563	,17178
1,22795	-,00481	-,32396	,18714
-,46293	1,25848	-,19699	,94587
-,40708	1,21412	,23032	1,01276
-,05869	1,07693	1,06708	,99975
-,56532	-1,40870	-,64124	,20562
-,49171	-,39615	-2,00352	1,01990
-,09193	-,48774	,88229	,16864
3,24170	1,17020	1,17897	-,67701
1,67977	-1,26933	-,20234	,21296
-,14478	-,04000	-,39088	,18372
-,61226	,16669	-,69443	-,70129
-,05444	-1,19683	,34084	,20990
-,51182	1,40552	-,77016	-1,62534
-,56854	,51715	-1,56974	-,71370
1,83944	,96685	-1,04854	-,69059
-,51131	-,17463	-,64264	,17807

ANÁLISIS DISCRIMINANTE LINEAL (LDA)

Estadísticas de grupo

dummy_room_price		Media	Desviación estándar	N válido (por lista) No ponderados	N válido (por lista) Ponderados
1,00	room_price	123,3569	31,91350	112860	112860,000
	days_in_advance	52,8443	69,74477	112860	112860,000
	months_in_advance	1,3379	2,27529	112860	112860,000
	hotel_category	3,6326	,58674	112860	112860,000
	rooms_booked	1,4476	,80090	112860	112860,000
	guests_per_room	2,2187	,81982	112860	112860,000
	rooms_available	18,5744	9,43452	112860	112860,000
	Efecto finde	,2946	,45587	112860	112860,000
2,00	room_price	242,3747	57,77669	87140	87140,000
	days_in_advance	41,2024	61,41938	87140	87140,000
	months_in_advance	1,0015	1,97522	87140	87140,000
	hotel_category	4,5896	,53979	87140	87140,000
	rooms_booked	1,4314	,77932	87140	87140,000
	guests_per_room	2,2912	,83993	87140	87140,000
	rooms_available	14,9866	9,52518	87140	87140,000
	Efecto finde	,3753	,48420	87140	87140,000
Total	room_price	175,2129	74,24217	200000	200000,000
	days_in_advance	47,7719	66,49702	200000	200000,000
	months_in_advance	1,1914	2,15616	200000	200000,000
	hotel_category	4,0496	,73918	200000	200000,000
	rooms_booked	1,4406	,79161	200000	200000,000
	guests_per_room	2,2503	,82942	200000	200000,000
	rooms_available	17,0112	9,63968	200000	200000,000
	Efecto finde	,3298	,47013	200000	200000,000

Prueba de igualdad de medias de grupos

	Lambda de Wilks	F	gl1	gl2	Sig.
room_price	,368	343270,595	1	199998	<,001
days_in_advance	,992	1518,647	1	199998	<,001
months_in_advance	,994	1204,651	1	199998	<,001
hotel_category	,588	140190,439	1	199998	<,001
rooms_booked	1,000	20,459	1	199998	<,001
guests_per_room	,998	377,195	1	199998	<,001
rooms_available	,966	7051,867	1	199998	<,001
Efecto finde	,993	1458,333	1	199998	<,001

H0 las medias son iguales
H1 las medias NO son iguales

En nuestro modelo sus valores son **todos menores de 0'05**, por lo que rechazamos H0 y NO rechazamos H1,es decir, **las variables son significativas para el análisis discriminante**, por lo que la media de los grupos de cada una son distintas

La variable room_price es la que mejor discrimina por sí sola, al tener la Lambda más baja (0,368).

Le sigue hotel_category con 0,588.

Variables como rooms_booked (1,000) prácticamente no aportan diferenciación individual entre los grupos.

Lambda de Wilks

Lambda de Wilks

Prueba de funciones	Lambda de Wilks	Chi-cuadrado	gl	Sig.
1	,957	8845,425	5	<,001

Lambda de Wilks (λ = 0,957) y el p-valor < 0,001, permite rechazar la H0 de igualdad de medias entre los grupos. Por lo que existen diferencias significativas entre los grupos y el modelo es significativo.

Autovalores

Función	Autovalor	% de varianza	% acumulado	Correlación canónica
1	,045[a]	100,0	100,0	,208

a. Se utilizaron las primeras 1 funciones discriminantes canónicas en el análisis.

El autovalor (0,045) es relativamente bajo, lo que sugiere que la capacidad de discriminación del modelo es limitada en términos absolutos. Pero vemos que la correlación canónica (0,208), que mide la relación entre la variable discriminante y la pertenencia al grupo. Al ser un valor cercano a 0, implica una relación débil, es decir, que tiene una capacidad de clasificación baja.

ECUACIÓN DEL MODELO DISCRIMINANTE

Coeficientes de la función discriminante canónica

	Función 1
months_in_advance	,177
rooms_booked	,059
guests_per_room	-,255
rooms_available	,089
Efecto finde	-,385
(Constante)	-1,107

Coeficientes no estandarizados

Y= 0,177*months_in_advance + 0,059*rooms_booked - 0,255*guest_per_room + 0,089*rooms_available - 0,385*efecto finde - 1,107

Matriz de estructuras

	Función 1
rooms_available	,883
Efecto finde	-,402
months_in_advance	,365
guests_per_room	-,204
rooms_booked	,048

Correlaciones dentro de grupos combinados entre las variables discriminantes y las funciones discriminantes canónicas estandarizadas
Variables ordenadas por el tamaño absoluto de la correlación dentro de la función.

Y= 0,883*months_in_advance - 0,402*rooms_booked +0,365*guest_per_room - 0,204*rooms_available +0,048*efecto finde +0,048

Funciones en centroides de grupo

dummy_room_price	Función 1
1,00	,187
2,00	-,242

Las funciones discriminantes canónicas sin estandarizar se han evaluado en medias de grupos

Probabilidades previas para grupos

dummy_room_price	Previa	Casos utilizados en análisis: No ponderados	Casos utilizados en análisis: Ponderados
1,00	,500	112860	112860,000
2,00	,500	87140	87140,000
Total	1,000	200000	200000,000

Obtención del punto de Corte-clasificar
C = (D1+D2)/2 - Ln(πII/πI) = (0,187 - 0,242)/2 - Ln (0,5/0,5) = -0,0275

Creamos una variable dummy llamada “dummy_room_price” donde según la media (175€) del precio de la habitación clasificamos en Grupo 1 (buen precio) por debajo de la media y Grupo 2 (no buen precio) por encima de la media

Grupo1 - “buen precio”

Grupo2 - “no buen precio”

Ecuaciones de Fisher

Coeficientes de función de clasificación

	dummy_room_price	
	1,00	2,00
months_in_advance	,298	,222
rooms_booked	2,317	2,291
guests_per_room	3,228	3,337
rooms_available	,241	,203
Efecto finde	2,644	2,809
(Constante)	-8,778	-8,315

Funciones discriminantes lineales de Fisher

F	F1	F2	F2-F1	Variables
months_in_advance	0,298	0,222	-0,076	3
rooms_booked	2,317	2,291	-0,026	4
guest_per_room	3,228	3,337	0,109	2
rooms_available	0,241	0,203	-0,038	21
efecto finde	2,644	2,809	0,165	1 (fin de semana)
Constante	-8,778	-8,315	0,463	-8,778

En la columna “Variables” ponemos como ejemplo el “Hotel X”, ahora metemos los datos en la ecuación

Y= 3*months_in_advance - 4*rooms_booked +2*guest_per_room - 21*rooms_available +efecto finde +(-8,778)

Resultados de clasificación[a]

			Pertenencia a grupos pronosticada		
		dummy_room_price	1,00	2,00	Total
Original	Recuento	1,00	61841	51019	112860
		2,00	33699	53441	87140
	%	1,00	54,8	45,2	100,0
		2,00	38,7	61,3	100,0

a. 57,6% de casos agrupados originales clasificados correctamente.

Hemos clasificado 112860 como “buen precio”, es decir, un precio por debajo de la media (175,2129) pero realmente 61841 datos son los considerados por el modelo como “buen precio” representa el 54,8% de los datos, por lo que 51019 datos inicialmente los hemos clasificado como “buen precio” pero según el modelo no lo son.

MODELO LOGÍSTICO MULTINOMIAL

Vamos a realizar un análisis mediante el modelo logístico multinomial. Para ello cogemos la variable “meal plan” como dependiente, ya que presenta más de dos categorías. Hemos puesto que:

- 1 = sólo habitación
- 2 = desayuno
- 3 = media pensión

MEAL_PLAN

		Frecuencia	Porcentaje	Porcentaje válido	Porcentaje acumulado
Válido	1,00	108017	54,0	55,1	55,1
	2,00	58604	29,3	29,9	85,0
	3,00	29448	14,7	15,0	100,0
	Total	196069	98,0	100,0	
Perdidos	Sistema	3931	2,0		
Total		200000	100,0		

A continuación vemos la calidad del modelo, además de analizar la matriz de clasificación.

Resumen de procesamiento de casos

		N	Porcentaje marginal
dummy_room_price	1,00	112860	56,4%
	2,00	87140	43,6%
Efecto finde	entre semana	134048	67,0%
	finde semana	65952	33,0%
Válidos		200000	100,0%
Perdidos		0	
Total		200000	
Subpoblación		199966[a]	

a. La variable dependiente sólo tiene un valor observado en 199966 (100,0%) subpoblaciones.

En esta tabla vemos la distribución real de nuestra muestra.

El grupo de hoteles con precio < 175,21 representa el 56,4% de la muestra (112.860 casos), mientras que el grupo > 175,21 representa el 43,6% (87.140 casos). Hay una diferencia de casi 13 puntos porcentuales entre grupos. Esto significa que el modelo tiene una tendencia natural a "aprender" mejor los patrones de los hoteles baratos porque tiene más ejemplos de ellos.

En el resumen podemos ver que no tenemos ningún valor pérdido,todos los datos de nuestra base tienen información por eso nos sale 0 valores perdidos.

Mirando la matriz de clasificación vemos que el modelo da valores muy bajos en 2 = “desayuno”, 3 = “media pensión”. Con el valor “sólo habitación” = 1 vemos que es el valor mejor predicho, lo cual tiene sentido ya que es el valor que más se repite.
Pero mirando al criterio 2 nos damos cuenta que da 0 en los demás criterios por lo que decidimos pasar de un Modelo de Multinomial Logistico a un Modelo Binomial Logístico, eliminado el criterio 2 (desayuno).

H0: el modelo no se ajusta al modelo de regresión múltiple

H1: el modelo se ajusta al modelo de regresión múltiple

Estadísticos

1_3

N	Válido	137465
	Perdidos	62535
Media		1,4284
Mediana		1,0000
Moda		1,00
Desv. estándar		,82057
Varianza		,673
Asimetría		1,393
Error estándar de asimetría		,007
Curtosis		-,059
Error estándar de curtosis		,013
Rango		2,00
Mínimo		1,00
Máximo		3,00

Una vez eliminado el criterio “desayuno” sacamos los estadísticos de nuestra nueva variable “Dummy1_3_MEAL_PLAN” y vemos que ahora modelo trabaja con 137.465 casos válidos, lo que representa el 68,7% de la muestra total. Los 62.535 casos restantes (31,3%) se han definido como perdidos de forma intencionada al recodificar la variable “meal_plan” para excluir la categoría "Desayuno". Esta base de datos resultante sigue siendo representativa.

Vemos que la media es 1,42 por lo que nos vuelve confirmar que hay mas datos de “1= solo habitación” que de “3= media pensión”

Resumen de procesamiento de casos

Casos sin ponderar[a]		N	Porcentaje
Casos seleccionados	Incluido en el análisis	137465	68,7
	Casos perdidos	62535	31,3
	Total	200000	100,0
Casos no seleccionados		0	,0
Total		200000	100,0

a. Si la ponderación está en vigor, consulte la tabla de clasificación para el número total de casos.

En el resumen de procesamiento de casos, vemos los casos perdidos ya mencionados anteriormente.

Variables en la ecuación

		B	Error estándar	Wald	gl	Sig.	Exp(B)
Paso 0	Constante	-1,300	,007	39085,623	1	<,001	,273

Hipótesis del índice de wald

H0: Bi son iguales a 0

H1 Bi no son iguales a 0

Vemos que el valor de la B es negativo lo que nos sigue confirmando que hay más casos de “1=Solo habitación” que de “3=Media pensión”. El dato de “Wald” es 39085,623 lo cual es un dato enorme, mirando el p-valor vemos que como es menor 0,05 es significativa,

rechazamos H0 y aceptamos H1 por lo que las B no son iguales a 0

Tabla de clasificación[a]

			Pronosticado		
			1_3		
	Observado		1,00	3,00	Porcentaje correcto
Paso 1	1_3	1,00	103460	4557	95,8
		3,00	22320	7128	24,2
	Porcentaje global				80,4

a. El valor de corte es ,500

Capacidad Predictiva

Tasa de Acierto: 80,4%

Vemos que para la tasa de acierto el valor observado y el valor pronosticado es de un 80,4%

Tasa de Error: 19,6%

El modelo presenta una tasa de error del 19,6%, concentrada fundamentalmente en falsos negativos. El modelo tiende a clasificar por defecto a los clientes en la categoría de 'Solo habitación' debido a que estos predominan en la muestra.

Sensibilidad: 103460/(22320+103460) = 82,25%

Mirando la sensibilidad vemos que nuestro modelo explica el 82,25% de los “1=solo habitación) observados

Especificidad: 7128/(4557+7128) = 61%

Mirando vemos nuestro modelo explica el 61% de los casos “3=media pensión”

Resumen del modelo

Paso	Logaritmo de la verosimilitud -2	R cuadrado de Cox y Snell	R cuadrado de Nagelkerke
1	116475,311[a]	,174	,270

a. La estimación ha terminado en el número de iteración 5 porque las estimaciones de parámetro han cambiado en menos de ,001.

En esta tabla de Resumen del modelo observamos que los valores de **R cuadrado de Cox y Snell = 0,174 y R cuadrado de Nagelkerke** = 0,270 son moderados. Los valores de estos indicadores no suelen tomar valores muy altos.

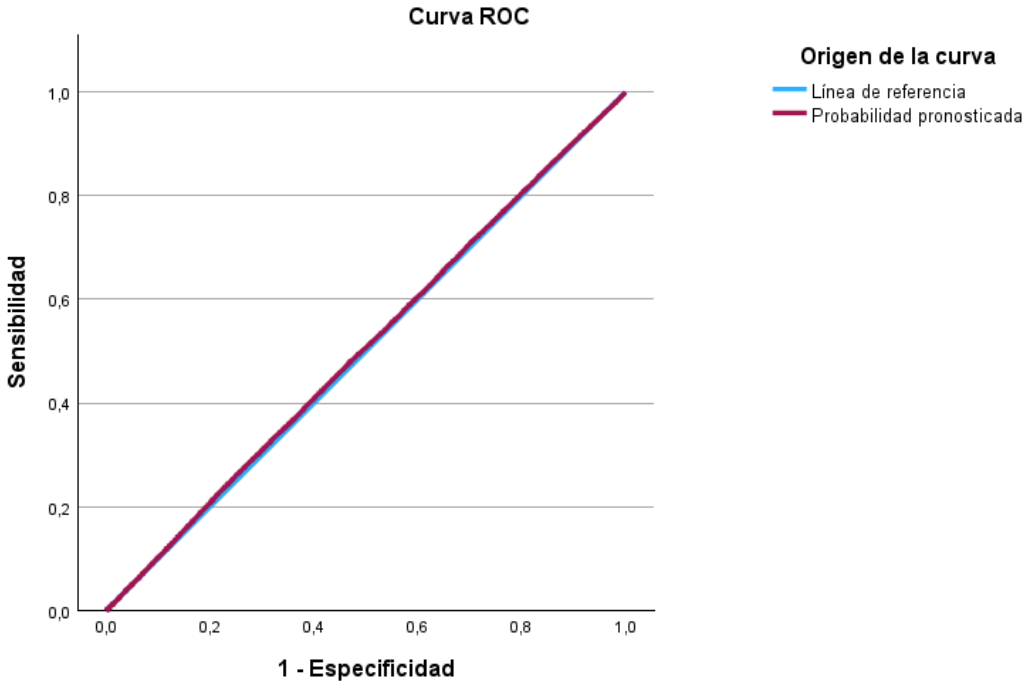
Respecto al valor del **-2 Logaritmo de la verosimilitud,** podemos ver que es elevado (**116475,311**), esto se debe principalmente al gran tamaño muestral utilizado, ya que con muestras tan amplias pequeñas desviaciones generan estadísticos muy altos.

Prueba de Hosmer y Lemeshow

Paso	Chi-cuadrado	gl	Sig.
1	1484,393	8	<,001

El estadístico **chi-cuadrado** también presenta un valor elevado y un nivel de significación <0,001, por lo que se rechaza H0 de buen ajuste del modelo. Esto indica que existen diferencias entre los valores observados y los estimados. Pero, al ser un tamaño muestral tan grande, esta prueba tiende a detectar diferencias significativas mínimas entre los valores observados y los estimados por el modelo. Por lo tanto, aunque el contraste indica diferencias, el modelo tiene una capacidad predictiva global aceptable.

ROC



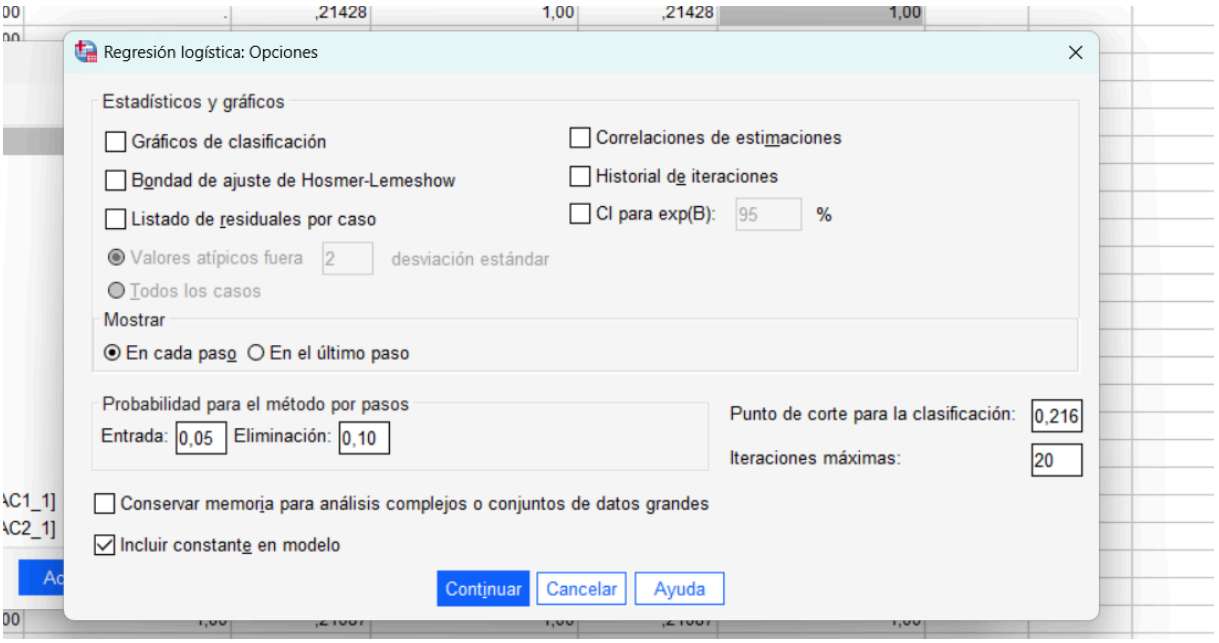
A pesar de obtener una tasa de acierto global del 80,4%, la **Curva ROC** muestra un área cercana a 0,5 (similar al azar). Esto se debe al fuerte desbalance de la muestra, donde la predominancia de la categoría 'Solo habitación' provoca que las probabilidades

pronosticadas por el modelo estén muy concentradas en valores bajos.

Por lo que modelo es eficaz para la clasificación masiva, pero carece de potencia para discriminar individualmente a los sujetos con mayor probabilidad de contratar Media Pensión frente a los de Solo habitación.

2862	,2164245	,240	,231	,009
2863	,2164253	,240	,231	,009
2864	,2164276	,240	,231	,009
2865	,2164306	,238	,228	,009
2866	,2164315	,237	,228	,010
2867	,2164329	,237	,228	,010
2868	,2164348	,237	,227	,010
2869	,2164355	,237	,227	,010
2870	,2164360	,237	,227	,010
2871	,2164368	,237	,227	,010
2872	,2164372	,236	,227	,009
2873	,2164378	,236	,227	,009
2874	,2164390	,236	,227	,009

Debido a que nuestra muestra contiene un gran cantidad de datos, los resultados de la tabla de “Coordenadas de la curva de ROC” han sido transformados en un documento Excel para poder localizar el punto de corte (0,2164368), mirando el Índice de Youden vemos que nos da valores muy bajos, teniendo su valor máximo en 0,010.



Resumen del modelo

Paso	Logaritmo de la verosimilitud -2	R cuadrado de Cox y Snell	R cuadrado de Nagelkerke
1	142818,907[a]	,000	,000

a. La estimación ha terminado en el número de iteración 4 porque las estimaciones de parámetro han cambiado en menos de ,001.

Bondad de ajuste

Tras cambiar el punto de corte vemos que tanto el **R cuadrado de Cox y Snell** como el **R cuadrado de Nagelkerke** presentan un valor de 0,000. Este resultado indica que las variables independientes introducidas no tienen ninguna capacidad para explicar la varianza de la variable dependiente.

-2 Log de la verosimilitud El incremento del estadístico **-2 Log de la verosimilitud hasta** 142.818,9 confirma un empeoramiento drástico del ajuste. Al aumentar este valor, se evidencia que la incertidumbre del modelo es máxima y que los predictores no están logrando reducir el error en la clasificación.

Debido a que los coeficientes de determinación son nulos, se concluye que este modelo específico carece de validez predictiva y no puede ser utilizado para la toma de decisiones estratégicas. Por lo que con el punto de corte original el modelo consigue explicar mejor la muestra.

Tabla de clasificación[a]

			Pronosticado		
			1_3		
	Observado		1,00	3,00	Porcentaje correcto
Paso 1	1_3	1,00	83449	24568	77,3
		3,00	22469	6979	23,7
	Porcentaje global				65,8

a. El valor de corte es ,216

Mirando la tabla de clasificación vemos que con el nuevo punto de corte la tasa de acierto se reduce lo cual nos dice que con el nuevo punto de corte el modelo tiene una menor tasa de acierto.

Variables en la ecuación

		B	Error estándar	Wald	gl	Sig.	Exp(B)
Paso 0	Constante	-1,300	,007	39085,623	1	<,001	,273

En la tabla de Variables en la ecuación podemos observar que los coeficientes pierden capacidad explicativa, ya que los pseudo coeficientes de determinación toman valores nulos y el ajuste global empeora significativamente. El incremento del -2 Logaritmo de la

verosimilitud refleja un aumento del error y de la incertidumbre del modelo.

Por lo tanto, **el nuevo punto de corte** obtenido mediante la curva ROC **no resulta útil**. Aunque minimiza algunos errores de significación, provoca una pérdida importante de capacidad explicativa y de precisión global. Por ello, llegamos a la conclusión de que el modelo original con el punto de corte inicial ofrece un ajuste más estable y una capacidad de clasificación para la muestra analizada.